

图像分类

李宇楠

计算机科学与技术学院

2025/12/1



1

图像分类的任务与挑战

2

传统图像分类方法

3

数据驱动的图像分类方法

4

相关数据集介绍



一、图像分类的任务与挑战

图像分类:

计算机视觉的核心任务，是一个输入图像，输出对该图像内容分类的描述的问题

$f(\text{苹果}) = \text{“苹果”}$

$f(\text{番茄}) = \text{“番茄”}$

$f(\text{牛}) = \text{“牛”}$



一、图像分类的任务与挑战

图像分类:

计算机视觉的核心任务，是一个输入图像，输出对该图像内容分类的描述的问题

$f(\text{苹果}) = \text{“苹果”}$

$f(\text{番茄}) = \text{“番茄”}$



$f(\text{牛}) = \text{“牛”}$



一、图像分类的任务与挑战

图像分类:

计算机视觉的核心任务，是一个输入图像，输出对该图像内容分类的描述的问题






一、图像分类的任务与挑战

图像分类:

计算机视觉的核心任务，是一个输入图像，输出对该图像内容分类的描述的问题




一、图像分类的任务与挑战

图像分类任务

图像分类指根据各自在图像信息中所反映的不同特征，对不同类别的目标进行区分。在计算机视觉领域，图像分类问题就是根据已有的分类标签合集，对于输入图像，从分类标签集合中挑选合适的标签分配给该输入图像。


图像分类是计算机视觉中最基础的一个任务，也是图像分割、目标跟踪、行为分析等其他高层视觉任务的基础。伴随着数据集规模的增长以及图像分类模型性能的提升。现在，在ImageNet 这样的超过1000万图像，超过2万类的数据集中，计算机的图像分类水准已经超过了人类。






一、图像分类的任务与挑战


图像分类的挑战



视角变化



外观形变



障碍物遮挡





光照变化



一、图像分类的任务与挑战


图像分类的挑战



二、传统图像分类方法

传统图像分类方法

在对图像分类的早期研究中，为了更好地描述图片的颜色、轮廓等信息，研究者一般通过精心设计的一些手工特征来对其加以表征。这是因为这些手工特征不像神经网络一样需要长时间的训练，并且能在强大的理论保证下提供可以预测的结果。而如何选择、提取、使用这些手工特征对最终算法的精度有着很重要的影响。基于传统方法的图像分类算法一般包含底层特征提取、特征编码、特征汇聚、分类器分类这四个部分。





二、传统图像分类方法

传统图像分类方法

底层特征是物体分类与检测框架中的第一步，底层特征提取方式有两种：一种是基于兴趣点检测，另一种是采用密集提取的方式。兴趣点检测算法通过某种准则选择具有明确定义的、局部纹理特征比较明显的像素点、边缘、角点、区块等，并且通常能够获得一定的几何不变性，从而可以在较小的开销下得到更有意义的表达。而第二种则是密集提取的方式，从图像中按固定的步长、尺度提取出大量的局部特征描述，大量的局部描述尽管具有更高的冗余度，但信息更加丰富。



二、传统图像分类方法

传统图像分类方法



类分数


$$f(x) = Wx$$





二、传统图像分类方法


传统图像分类方法





二、传统图像分类方法

传统图像分类方法




**红色点和蓝色点无法用
线性分类器
分开**




二、传统图像分类方法

传统图像分类方法



红色点和蓝色点无法用线性分类器分开

$$f(x, y) = (r(x, y), \theta(x, y))$$




在特征变换后，可以用线性分类器分开



二、传统图像分类方法

传统图像分类方法

特征1：颜色直方图






二、传统图像分类方法

传统图像分类方法

特征2：HOG特征



将图像分割为8*8的小区域，每个区域内将每个点处的梯度按方向统计在9个方向区间内



示例：320*240的图片，分割为40*30个小区域，每个区域用9个数字统计9个梯度方向的累加幅值，则特征向量共
 $40*30*9=10800$

二、传统图像分类方法


传统图像分类方法

特征3：视觉词袋

Step 1: Build codebook




Extract random
patches



Cluster patches to
form "codebook"
of "visual words"



Step 2: Encode images




Fei-Fei and Perona, "A bayesian hierarchical model for learning natural scene categories", CVPR 2005



二、传统图像分类方法

传统图像分类方法





二、传统图像分类方法

- 向量量化编码：向量量化编码是简单的特征编码。向量量化编码是通过一种量化的思想，使用一个较小的特征集合来对底层特征进行描述，达到特征压缩的目的。向量量化编码只在最近的视觉单词上响应为 1，因而又称为硬量化编码、硬投票编码，这意味着向量量化编码只能对局部特征进行很粗糙的重构。但向量量化编码思想简单、直观，也比较容易高效实现，因而从2005年第一届PASCAL VOC竞赛以来，就得到了广泛的使用。
- 软量化编码（核词典编码）：在实际图像中，图像局部特征常常存在一定的模糊性，即一个局部特征可能和多个视觉单词差别很小，这个时候若使用向量量化编码将只利用距离最近的视觉单词，而忽略了其他相关性很高的视觉单词。而在软量化编码（又称核视觉词典编码）中局部特征不再使用一个视觉单词描述，而是由距离最近的多个视觉单词加权后进行描述，有效解决了视觉单词的模糊性问题，提高了物体识别的精度。
- 稀疏编码：稀疏编码算法的目的就是找到一组基向量，使得我们能将输入向量表示为这些基向量的线性组合。稀疏编码的主要思想通过最小二乘重构加入稀疏约束来实现在一个过完备基上响应的稀疏性。目前更多使用的是 l_1 约束，可以更加有效地进行迭代优化，得到稀疏表达。

特征汇聚

特征编码之后一般会经过空间特征约束，也称作空间特征汇聚。特征汇聚是指在一个空间范围内，对每一维特征取最大值或者平均值，可以获得一个紧致的特征向量作为图像的特征表达。这种图像表达可以获得一定的特征不变形，同时也避免了使用特征集进行图像表达的高额代价。最大值汇聚在绝大部分情况下的性能要优于平均值汇聚，也在物体分类中使用最为广泛。其中金字塔特征匹配是一种常用的特征聚会方法，这种方法提出将图像均匀分块，然后每个区块里面单独做特征汇聚操作并将所有特征向量拼接起来作为图像最终的特征表达。



三、数据驱动的图片分类方法

- 收集带有标签的图像数据库
- 使用机器学习算法训练图像分类器
- 用测试图像评估分类器的效果

Example training set






三、数据驱动的图片分类方法

- 收集带有标签的图像数据库
- 使用机器学习算法训练图像分类器
- 用测试图像评估分类器的效果

```
def train(train_images, train_labels):  
    # build a model of images -> labels  
  
def predict(image):  
    # evaluate the model on the image  
    return class_label
```

三、数据驱动的图片分类方法





三、数据驱动的图片分类方法

- **线性分类器**
 - **映射函数: 原始图像到分类结果**
 - **损失函数: 评价预测分数与实际标签的一致性**



三、数据驱动的图片分类方法

参数化途径



[32x32x3]

图像->像素矩阵
3072个数字

图像

参数

$$f(\mathbf{x}, \mathbf{W})$$

N个数字
表示每个类别的
概率



三、数据驱动的图片分类方法

参数化途径



[32x32x3]

图像->像素矩阵
3072个数字

$$\boxed{f(x, W)}_{N \times 1} = \boxed{W}_{N \times 3072} \boxed{x}_{3072 \times 1} \boxed{(+b)}_{N \times 1}$$

N个数字
表示每个类别的
概率

参数，或“权重”



三、数据驱动的图片分类方法

映射函数的定义

$$f(x_i, W, b) = Wx_i + b$$

数据（图像）

分类结果

权重


偏置向量

参数



三、数据驱动的图片分类方法

假设图像中有4个像素，分3类（猫、车、蛙）



三、数据驱动的图片分类方法

$$f(x, W) = Wx + b$$

对于某个W，3张图片的
示例类别分数

如何评判W好还是不好？



airplane	-3.45	-0.51	3.42
automobile	-8.87	6.04	4.64
bird	0.09	5.31	2.65
cat	2.9	-4.22	5.1
deer	4.48	-4.19	2.64
dog	8.02	3.58	5.55
frog	3.78	4.49	-4.34
horse	1.06	-4.37	-1.5
ship	-0.36	-2.09	-4.79
truck	-0.72	-2.93	6.14

三、数据驱动的图片分类方法

$$f(x, W) = Wx + b$$

要做的：

1. 定义一个损失函数：在训练集上评估我们对分类分数的不满意程度
2. 优化方法：求解参数的方法，以最小化损失函数



airplane	-3.45	-0.51	3.42
automobile	-8.87	6.04	4.64
bird	0.09	5.31	2.65
cat	2.9	-4.22	5.1
deer	4.48	-4.19	2.64
dog	8.02	3.58	5.55
frog	3.78	4.49	-4.34
horse	1.06	-4.37	-1.5
ship	-0.36	-2.09	-4.79
truck	-0.72	-2.93	6.14



三、数据驱动的图片分类方法

假设有3个类别，训练集有3个样本对于某个W，评分函数 $f(x, W) = Wx$



猫	3.2	1.3	2.2
车	5.1	4.9	2.5
青蛙	-1.7	2.0	-3.1

损失函数评估现有分类器的优劣

给定一个样本集

$$\{(x_i, y_i)\}_{i=1}^N$$

其中 x_i 是图片， y_i 是(整数)标记

数据集上的损失函数是
每个样本的损失之和

$$L = \frac{1}{N} \sum_i L_i(f(x_i, W), y_i)$$




三、数据驱动的图片分类方法

给定真实标签 y_i 、预测结果 $f(x_i, W)$

- 我们对分类结果不满意的程度
- 损失函数或目标/成本函数度量这种不满意的程度
- 在训练期间,要找到最小化损失函数的参数 W

三、数据驱动的图片分类方法

偏置向量b





三、数据驱动的图片分类方法

Softmax函数

- 分数不是很直观
- 思路: 将分数归一化得到概率分布
- 是逻辑斯蒂(logistic)回归向多分类的推广



三、数据驱动的图片分类方法

Softmax函数

$$s = f(x_i, W) = Wx_i \quad P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

$$[1, -2, 0] \rightarrow [e^1, e^{-2}, e^0] = [2.71, 0.14, 1] \rightarrow [0.7, 0.04, 0.26]$$

解释: 将分数归一化到0到1之间, 类似概率分布



三、数据驱动的图片分类方法

Softmax函数

$$P(y_i | x_i; W) = P(Y = y_i | X = x_i) = \frac{e^{s_{y_i}}}{\sum_j e^{s_j}}$$

我们希望 $P(y_i | x_i; W)$ 越大越好，即 $\log P(y_i | x_i; W)$ 越大越好，因此将损失函数定义为

$$L_i = -\log P(y_i | x_i; W) = -\log \frac{e^{s_{y_i}}}{\sum_j e^{s_j}}$$



三、数据驱动的图片分类方法

数据驱动的方法


Softmax分类



$$L_i = -\log \frac{e^{s_{y_i}}}{\sum_j e^{s_j}}$$

问题2:初始时W往往、
很小，因此 $s \approx 0$ ，损
失是多少？

未归一化的概率



$$L_i = -\log(0.13) = 0.89$$

未归一化的对数概率

概率




交叉熵损失函数

- 交叉熵 H $H(p, q) = -\sum_x p(x)\log q(x)$
- p 是真实分布 (1 为正确的类), q 是估计分布
- Softmax分类器最小化交叉熵
- 即最小化 KL散度 (相对熵) : p 与 q 之间的差异(距离)
- $D_{KL}(p||q) = \sum_x p(x)\log \frac{p(x)}{q(x)} = \sum_x p(x)\log \frac{1}{q(x)} - \sum_x p(x)\log \frac{1}{p(x)} = H(p, q) - H(p)$



三、数据驱动的图片分类方法

LeNet




LeNet是最早的卷积神经网络之一。1998年，Yan LeCun第一次将LeNet卷积神经网络应用到图像分类上，在手写数字识别任务中取得了巨大成功。LeNet通过连续使用卷积和池化层的组合提取图像特征。LeNet一个经典的卷积神经网络，它包含着一些重要的特性，这些特性仍然是现在CNN网络的核心。

- 卷积层由卷积，池化，非线性激活函数构成。从1998年至今，经过20年的发展后，卷积神经网络依然遵循着这样的设计思想。其中，卷积发展出了很多的变种，池化则逐渐被带步长的卷积完全替代，非线性激活函数更是演变出了很多的变种。
- 稀疏连接，也就是局部连接，这是以卷积神经网络为代表的技术能够发展至今的最大前提。利用图像的局部相似性，这一区别于传统全连接的方式，推动了整个神经网络技术的发展。

三、数据驱动的图片分类方法

AlexNet




随着技术的进步和发展，计算机的算力越来越强大，尤其是在GPU并行计算能力的推动下，复杂神经网络的计算也变得更加容易实施。另一方面，互联网上涌现出越来越多的数据，极大的丰富了数据库。同时也有越来越多的研究人员开始专门针对神经网络做算法和模型的优化，Alex Krizhevsky等人提出的AlexNet以很大优势获得了2012年ImageNet比赛的冠军。这一成果极大的激发了产业界对神经网络的兴趣，开创了使用深度神经网络解决图像问题的途径，随后也在这一领域涌现出越来越多的优秀成果。AlexNet与LeNet相比，具有更深的网络结构，包含5层卷积和3层全连接，同时使用了如下三种方法改进模型的训练过程：

- 数据增广：深度学习中常用的一种处理方式，通过对训练随机加一些变化，比如平移、缩放、裁剪、旋转、翻转或者增减亮度等，产生一系列跟原始图片相似但又不完全相同的样本，从而扩大训练数据集。通过这种方式，可以随机改变训练样本，避免模型过度依赖于某些属性，能从一定程度上抑制过拟合。
- 使用Dropout抑制过拟合
- 使用ReLU激活函数减少梯度消失现象



一、神经网络



VGG




2014年Simonyan和Zisserman提出了VGG，其命名来源于论文作者所在的实验室Visual Geometry Group。AlexNet模型通过构造多层网络，取得了较好的效果，但是并没有给出深度神经网络设计的方向。VGG通过使用一系列大小为3x3的小尺寸卷积核和pooling层构造深度卷积神经网络，并取得了较好的效果。VGG模型因为结构简单、应用性极强而广受研究者欢迎，尤其是它的网络结构设计方法，为构建深度神经网络提供了方向。

三、数据驱动的图片分类方法

GoogLeNet



(a) Basic Inception Module Concept





(b) Inception Module with Dimension Reductions

GoogLeNet是2014年ImageNet比赛的冠军。一般来说对于提升网络性能直接的办法就是增加网络深度和宽度，但一味地增加深度和宽度，会给网络带来过拟合、计算复杂度大、梯度消失等问题。而GoogLeNet提出了Inception的方法。Inception就是把多个卷积或池化操作，放在一起组装成一个网络模块，设计神经网络时以模块为单位去组装整个网络结构。在之前的卷积神经网络里，一层往往只使用一种操作，比如卷积或者池化，而且卷积操作的卷积核尺寸也是固定大小的。但是，在实际情况下，在不同尺度的图片里，需要不同大小的卷积核，这样才能使性能最好。所以，GoogLeNet希望让网络通过Inception模块自己去选择。一个Inception模块中并列提供多种卷积核的操作，网络在训练的过程中通过调节参数自己去选择使用。



三、数据驱动的图片分类方法

ResNet



ResNet(Residual Network) 是2015年ImageNet图像分类、图像物体定位和图像物体检测比赛的冠军。针对随着网络训练加深导致准确度下降的问题，ResNet提出了残差学习方法来减轻训练深层网络的困难。ResNet在已有的神经网络设计思路(BN, 小卷积核，全卷积网络)的基础上，引入了残差模块。每个残差模块包含两条路径，其中一条路径是输入特征的直连通路，另一条路径对该特征做两到三次卷积操作得到该特征的残差，最后再将两条路径上的特征相加。



四、相关数据集

数据驱动的方法



早期物体分类研究集中于一些较为简单的特定任务，如光学字符识别（Optical Character Recognition, OCR）、形状分类等。OCR中数字手写识别是一个得到广泛研究的课题，相关数据库中最著名的是MNIST数据库。MNIST是一个数字手写识别领域的标准评测数据集，数据库大小是60000，一共包含10类阿拉伯数字，每类提供5000张图像进行训练，1000张进行测试。MNIST的图像大小为 28×28 ，所有图像为手写数字并且不同图片之间存在较大的形变。

四、相关数据集

CIFAR

CIFAR-10和CIFAR-100数据库分别包含了10类和100类物体类别。这两个数据库的图像均为彩色图像且尺寸都是 32×32 。CIFAR-10包含6万幅图像，其中5万幅用于模型训练，1万幅用于测试，每一类物体有5000张图像用于训练，1000张图像用于测试。CIFAR-100与CIFAR-10组成类似，不同的是包含了更多的类别，即20个大类，这些大类又可细分为100个小类别，每类包含600幅图像。CIFAR-10和CIFAR-100数据库尺寸较小，但是数据规模相对较大，非常适合复杂模型特别是深度学习模型训练，因而成为深度学习领域主流的物体识别评测数据集。


airplane



automobile



bird



cat




deer



dog



frog



horse



ship



truck



四、相关数据集

PASCAL VOC



PASCAL VOC从2005年到2012年每年都发布关于分类、检测、分割等任务的数据库，并在相应数据库上举行了算法竞赛，极大地推动了视觉研究的发展进步。最初2005年PASCAL VOC数据库只包含人、自行车、摩托车、汽车共4类，2006年类别数目增加到10类，2007年开始类别数目固定为20类，以后每年只增加部分样本。PASCAL VOC数据库中物体类别均为日常生活中常见的物体，如交通工具、室内家具、人、动物等。PASCAL VOC数据库共包含9963张图片，每类大概包含96~2008张图像，均为一般尺寸的自然图像。PASCAL VOC数据库虽然类别数较少，但由于图像中物体尺度变化较大，且每张图像可能包含多个不同类别物体实例，因而对于分类与检测任务都很具有挑战性。该数据库的提出，催生了大批优秀的理论与算法，将物体识别的研究推向了一个新的高度。

四、相关数据集

ImageNet



ImageNet全库截止2013年共有1400万张图像，2.2万个类别，平均每类包含1000张图像。这是目前视觉识别领域最大的有标注的自然图像分辨率的数据集，尽管图像本身基本还是以目标为中心构建的，但是海量的数据和海量的图像类别，使得该数据库上的分类任务依然极具挑战性。