

目标跟踪

李宇楠

计算机科学与技术学院

2025/12/5



1

视频的形成

2

目标跟踪的任务与挑战

3

基于传统的目标跟踪方法

4

基于深度学习的目标跟踪方法

5

相关数据集




一、视频的形成

视频的形成

视觉暂留现象

光对视网膜所产生的视觉在光停止作用后，大脑神经网络中仍保留其影像0.1-0.4秒左右的图像，电影电视的拍摄和放映就是根据这个原理。原因是视神经的反应速度造成的




<https://www.bilibili.com/video/BV1uN4y1j7G3/>



一、视频的形成

视频的形成



二、目标跟踪的任务与挑战

目标跟踪:

目标跟踪是计算机视觉领域中的一项重点研究问题之一，其目标是在视频序列第一帧指定某目标，在后续帧中实现持续的跟踪目标。根据第一帧选定的目标个数不同，可将目标跟踪任务分为单目标跟踪和多目标跟踪。本次主要讲解单目标跟踪(Single Object Tracking, SOT)

视频的第一帧





第N帧预测目标状态



● ● ● ● ● ●

单目标跟踪



● ● ● ● ● ●

多目标跟踪

二、目标跟踪的任务与挑战

单目标跟踪任务:

对于给定的视频序列，单目标跟踪(Single Object Tracking, SOT)需要根据第一帧给定的待跟踪目标的状态(通常为边界框(Bounding Box))，实现对后续帧的目标的状态(位置及尺寸)的预测

视频的第一帧



第N帧预测目标状态



● ● ● ● ● ●

单目标跟踪

二、目标跟踪的任务与挑战

单目标跟踪的挑战

与目标检测不同，目标跟踪任务中的跟踪目标无指定类别，且跟踪场景复杂多变，存在目标尺度变化、背景干扰、相似目标干扰、运动模糊、目标遮挡甚至目标消失等诸多问题



尺度形变



光照变化



4





运动模糊




相似目标干扰

二、目标跟踪的任务与挑战

单目标跟踪的挑战



平面外旋转



平面内旋转



5



遮挡



超出视野范围

二、目标跟踪的任务与挑战

单目标跟踪的挑战

Human

背景复杂

Shaking

强光照干扰

FaceOcc


目标遮挡

Bolt

相似目标



三、基于传统的目标跟踪方法



三、基于传统的目标跟踪方法

子空间方法

- 子空间方法利用主成分分析（PCA）等降维方法提取目标的主要低维特征，在该特征的基础上，使用欧式距离等度量方法，计算模板和目标的相似程度

稀疏表示方法

- 稀疏表示方法通常将目标表示为一组目标模板和非目标模板的稀疏线性组合，通过求解L1范数的优化问题计算权重，利用计算得到的目标模板在下一帧中寻找重构误差最小的图像区域，即为跟踪结果


相关滤波方法

- 基于相关滤波的跟踪模型通过给定目标搜索区域并提取特征，利用相关滤波器与搜索区域的特征求相关生成响应图，其中，最大响应位置即为预测的目标位置。
- 由于互相关运算可利用快速傅里叶变换求解，因此基于相关滤波的跟踪模型效率非常高，满足实时跟踪的要求。

三、基于传统的目标跟踪方法

High-Speed Tracking with Kernelized Correlation Filters

KCF通过循环移位的方法实现密集采样，循环矩阵具有傅里叶变换对角化特性，利用该性质，可以快速计算。



三、基于传统的目标跟踪方法

High-Speed Tracking with Kernelized Correlation Filters

Inputs

- x : training image patch, $m \times n \times c$
- y : regression target, Gaussian-shaped, $m \times n$
- z : test image patch, $m \times n \times c$

Output

- responses: detection score for each location, $m \times n$

```
function alphaf = train (x, y, sigma, lambda)
    k = kernel_correlation(x, x, sigma);
    alphaf = fft2(y) ./ (fft2(k) + lambda);
end


function responses = detect (alphaf, x, z, sigma)
    k = kernel_correlation(z, x, sigma);
    responses = real(ifft2(alphaf .* fft2(k)));
end

function k = kernel_correlation (x1, x2, sigma)
    c = ifft2(sum(conj(fft2(x1)) .* fft2(x2), 3));
    d = x1(:)'*x1(:) + x2(:)'*x2(:) - 2 * c;
    k = exp(-1 / sigma^2 * abs(d) / numel(d));
end
```

三、基于传统的目标跟踪方法

ECO: Efficient Convolution Operators for Tracking

作者发现通过分析深度神经网络网络提取的特征发现大部分通道的响应值不高




	Conv-1	Conv-5	HOG	CN
Feature dimension, D	96	512	31	11
Filter dimension, C	16	64	10	3


三、基于传统的目标跟踪方法

ECO: Efficient Convolution Operators for Tracking

作者提出了使用混合高斯模型保存不同姿态的跟踪结果，每个组成部分对应一组相似的样本，在减少训练样本数量的同时保证了训练样本的多样性。



四、基于深度学习的目标跟踪方法



四、基于深度学习的目标跟踪方法

基于全卷积神经网络的目标跟踪算法

- 全卷积神经网络避免使用全连接层，可以输入任意大小的图像，同时，减少了全连接层的大量参数，加快了跟踪的速度。
- 与相关滤波方法相比，实现了端到端的跟踪模型，联合优化跟踪模型的参数，利用深度神经网络提取目标的深度特征，提升跟踪模型的性能。

基于Siamese网络的目标跟踪算法

- Siamese网络一般由两个子网络构成，将两个成对的图像分别送入不同的网络分支中，映射到新的特征空间，度量两个输入的相似程度
- 基于Siamese网络的跟踪模型避免了在线更新，通过离线训练的方式学习鲁棒的相似性度量模型，显著的提高了跟踪效率，满足实时的要求


基于Transformer的目标跟踪算法

- Transformer是一种基于 注意力机制的编码解码器结构，最初用于机器翻译任务。但随着ViT、DETR、Swin Transformer等模型的提出，在计算机视觉领域也掀起了研究Transformer的热潮，被广泛的应用于目标检测、图像分割、动作识别、目标跟踪等领域，达到并超过基于深度卷积神经网络的方法。
- 基于Transformer的目标跟踪算法通过自注意力机制，联合学习目标的时空特征，捕获全局和丰富的上下文相互依赖关系，提高跟踪的性能。

四、基于深度学习的目标跟踪方法

Visual tracking with fully convolutional networks

FCNT关注了神经网络中不同层的作用，其中深层特征更多的编码了目标的语义信息，浅层更多的提取了目标的空间信息。



原图


conv4-3的特征

conv5-3的特征


四、基于深度学习的目标跟踪方法

Visual tracking with fully convolutional networks

FCNT统计了目标区域内所有特征图的响应值，大多数特征图在目标区域内的响应值很小或为零。因此，有很多特征图与跟踪目标没有关系。即只选择少量的特征图，而在跟踪性能方面的损失很小。



conv4-3




conv5-3

四、基于深度学习的目标跟踪方法

Visual tracking with fully convolutional networks


- (1) 首先通过特征选择部分，选择与当前目标相关的特征通道。
- (2) 以深层特征conv5-3作为输入，提取目标的语义信息，用于区分目标背景。
- (3) 以浅层特征conv4-3作为输入，提取目标的空间信息，用于区分目标和相似干扰。





四、基于深度学习的目标跟踪方法

Siamese网络




Siamese网络由两个特征提取网络构成
这两个网络输入不同，但结构相同，且网络权重共享，即参数一致

四、基于深度学习的目标跟踪方法


Fully-Convolutional Siamese Networks for Object Tracking

SiamFC使用全卷积孪生网络进行相似性学习，来解决跟踪任意单个对象的问题，SiamFC将跟踪问题构建为了目标模板和搜索帧之间的相似度匹配问题，同时SiamFC也开启了Siamese网络结构在跟踪方法中的应用。



四、基于深度学习的目标跟踪方法

Fully-Convolutional Siamese Networks for Object Tracking



φ 表示Siamese网络的
特征提取网络的参数

*表示互相关操作
全卷积

z 表示目标模板， x 表示目标可能存在的区域

四、基于深度学习的目标跟踪方法


Fully-Convolutional Siamese Networks for Object Tracking

模板区域



模板区域尺寸为 $127 \times 127 \times 3$

搜索区域



搜索区域尺寸为 $255 \times 255 \times 3$


SiamFC的训练数据

根据目标所在位置中心裁剪，缺少部分用图像平均RGB值填充

四、基于深度学习的目标跟踪方法

SiamRPN++: Evolution of Siamese Visual Tracking with Very Deep Networks

SiamRPN++通过实验发现神经网络中的padding会破坏平移不变性，导致在训练基于siamese的跟踪模型时会学习到正样本都位于图像中心的位置偏见。




Shift是指目标相对图像中心的偏离距离

Shift=0表示没有偏移，Shift=16表示目标在16个单位距离的范围内均匀分布

四、基于深度学习的目标跟踪方法

SiamRPN++: Evolution of Siamese Visual Tracking with Very Deep Networks


分层聚合，借鉴RPN网络的思想，结合深度可分离卷积，预测目标的位置和尺度变化。




四、基于深度学习的目标跟踪方法

Transformer

Transformer由Encoder和Decoder两部分组成，其中每部分由基于多头自注意力机制的子网络构成




Scaled Dot-Product Attention



四、基于深度学习的目标跟踪方法



Learning Spatio-Temporal transformer for visual tracking

提出了一种新的端到端跟踪结构，采用编码器-解码器Transformer来提高传统卷积模型的性能。它能够捕获视频序列中空间和时间信息的全局特征依赖关系。同时提出使用动态更新模板。



四、基于深度学习的目标跟踪方法


Learning Spatio-Temporal transformer for visual tracking



四、基于深度学习的目标跟踪方法


Learning Spatio-Temporal transformer for visual tracking

将目标跟踪建模成一个直接的边界框预测问题。通过预测左上与右下角点热力图的方式，每帧直接得到一个最优的边界框，彻底摆脱了之前复杂且对超参敏感的后处理。



四、基于深度学习的目标跟踪方法

Joint Feature Learning and Relation Modeling for Tracking: A One-Stream Framework




Two-Stream two-stage

双流两阶段架构在特征提取阶段缺乏目标信息
双流两阶段的架构容易受到性能的影响

四、基于深度学习的目标跟踪方法

Joint Feature Learning and Relation Modeling for Tracking: A One-Stream Framework




Two-Stream two-stage

特征提取和特征融合统一在一个模块
不需要额外的重型关系建模模块，并行度高

四、基于深度学习的目标跟踪方法

Joint Feature Learning and Relation Modeling for Tracking: A One-Stream Framework

特征提取和关系建模相结合，提出了一个简单、整洁、有效的单流单阶段跟踪框架。
提出一个基于ViT网络的早期候选消除模块，用于及时逐步识别和丢弃属于背景的候选者，加速推理。






五、相关数据集

OTB

TB-50 Sequences.



OTB（Object Tracking Benchmark）是最早的视觉跟踪公开数据集，包括OTB2013和OTB2015，分别包含50个和100个视频序列。其中OTB2013是视频目标跟踪领域首个用于算法评估的基准数据集，OTB2015则是在OTB2013的基础上进一步扩大数据集。

挑战：光照变化、尺度变化、遮挡、非刚性物体变形、运动模糊、快速运动、平面内旋转、外平面旋转、出视野、背景干扰、低分辨率。

TrackingNet

TrackingNet是目标跟踪领域的第一个大规模数据集，是视频目标检测基准YouTube-BoundingBoxes (YT-BB) 的子集（选择31K序列），测试集包含511个没有公开真实标注框的视频。它涵盖了不同的对象类和场景，要求跟踪算法具有判别和生成能力，有效解决了基于深度学习的数据需求型跟踪算法缺乏专用的大规模数据集的问题。




挑战：尺度变化、纵横比变化、快速运动、低分辨率、出视野、光照变化、相机运动、运动模糊、背景杂波、相似物体、非刚性形变、平面内旋转、平面外旋转、部分遮挡、完全遮挡。

五、相关数据集

GOT-10k

GOT-10K (Generic Object Tracking) 是由中国科学院发布的目标跟踪数据集，该数据集为具有挑战性的大规模数集。数据集覆盖真实世界中的563种常见户外目标，包含约1万个训练序列和420个测试序列。目标包围框数量超过150万个，且均为人工标注。

它的主要特点是测试集与训练集在目标类上没有重叠，目的是评估视觉跟踪算法的泛化性。因此按照GOT-10k的测试协议，只使用GOT-10k训练集训练跟踪算法。



挑战：遮挡、尺度变化、纵横比变化（考虑进物体的非刚性形变和旋转）、光照变化、低分辨率

五、相关数据集

LaSOT

LaSOT (Large-scale Single Object Tracking) 是一个大规模、高质量、密集标注的长期跟踪数据集。为了减小潜在的类别偏差，为每个类别提供相同数量的序列。共包含85个类，其中70个类，每类包含20个视频序列；另外15类，每类包含15个视频序列。此外，考虑了视觉外观和自然语言的联系，不仅标注了边界框，而且增加了丰富的自然语言描述，以描述目标物体的外观。

共包含 1400 个视频序列（1120 个训练序列及280个测试序列）。数据集的平均视频长度超过2500帧，且逐帧采用手工标注。跟踪器在该数据集上的表现能直接反应目标的长时跟踪能力。


挑战：光照变化、完全遮挡、部分遮挡、非刚性旋转、运动模糊、快速运动、尺度变化、相机运动、旋转、背景杂波、出视野、纵横比变化。



Bear-12: "white bear walking on grass around the river bank"




Bus-19: "red bus running on the highway"



Horse-1: "brown horse running on the ground"



Person-14: "boy in black suit dancing in front of people"



Mouse-6: "white mouse moving on the ground around another white mouse"