

计算机视觉与深度学习新进展

李宇楠

计算机科学与技术学院

2025/12/11



1

循环卷积神经网络

2

生成模型

3

Transformer

4


自监督学习



一、循环卷积神经网络

循环卷积神经网络

CNN：层与层之间纵向连接
序列数据：视频、语音



$$s_t = f(Ux_t + Ws_{t-1})$$


$$o_t = g(Vs_t)$$

一、循环卷积神经网络


Long short-term memory

RNN的问题

- 无法处理长期记忆的问题
- 梯度消失



(a) RNN




(b) LSTM



一、循环卷积神经网络

Long short-term memory





$$c^t = z^f \odot c^{t-1} + z^i \odot z$$
$$h^t = z^o \odot \tanh(c^t)$$
$$y^t = \sigma(W' h^t)$$

Information flow of LSTM



一、循环卷积神经网络

Long short-term memory




Information flow of LSTM



一、循环卷积神经网络

Gate Recurrent Unit




$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$



$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$



将遗忘门和输入门整合为更新门，同时将cell state和hidden state整合起来

一、循环卷积神经网络

Memory Network



I : 把网络输入转化为特征向量;

G : 在模型获取输入后更新记忆单元;

O : 根据网络输入的特征向量对记忆单元进行相似度整合得到输出向量。

R : 将输出向量转化为所需的格式, 比如手势识别中的类别。




二、生成模型

生成对抗网络


生成模型vs判别模型

Discriminant Model



$$p(y|x)$$

Generative Model



$$p(x, y)$$




二、生成模型

生成对抗网络

► 生成模型包含两部分：

- 密度估计
- 采样






二、生成模型

生成对抗网络

生成网络

生成网络从潜在空间（latent space）中随机采样作为输入，其输出结果需要尽量模仿训练集中的真实样本。



如何学习生成网络？




二、生成模型

生成对抗网络

判别网络

判别网络的输入则为真实样本或生成网络的输出，其目的是将生成网络的输出从真实样本中尽可能分辨出来。



生成对抗网络

生成对抗网络的训练-MinMax博弈

对抗训练

- 生成网络要尽可能地欺骗判别网络。
- 判别网络将生成网络生成的样本与真实样本中尽可能区分出来。
- 两个网络相互对抗、不断调整参数，最终目的是使判别网络无法判断生成网络的输出结果是否真实。

算法 13.1: 生成对抗网络的训练过程

输入: 训练集 $\mathcal{D}$, 对抗训练迭代次数 T , 每次判别网络的训练迭代次数 K , 小批量样本数量 M

1 随机初始化 θ, ϕ ;

2 for $t \leftarrow 1$ to T do

 // 训练判别网络 $D(\mathbf{x}, \phi)$

3 for $k \leftarrow 1$ to K do

 // 采集小批量训练样本

4 从训练集 $\mathcal{D}$ 中采集 M 个样本 $\{\mathbf{x}^{(m)}\}, 1 \leq m \leq M$;

5 从分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 中采集 M 个样本 $\{\mathbf{z}^{(m)}\}, 1 \leq m \leq M$;

6 使用随机梯度上升更新 ϕ , 梯度为

$$\frac{\partial}{\partial \phi} \left[\frac{1}{M} \sum_{m=1}^M \left(\log D(\mathbf{x}^{(m)}, \phi) + \log (1 - D(G(\mathbf{z}^{(m)}, \theta), \phi)) \right) \right];$$

7 end

 // 训练生成网络 $G(\mathbf{z}, \theta)$

8 从分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 中采集 M 个样本 $\{\mathbf{z}^{(m)}\}, 1 \leq m \leq M$;

9 使用随机梯度上升更新 θ , 梯度为

$$\frac{\partial}{\partial \theta} \left[\frac{1}{M} \sum_{m=1}^M D(G(\mathbf{z}^{(m)}, \theta), \phi) \right];$$

10 end

输出: 生成网络 $G(\mathbf{z}, \theta)$

生成对抗网络

生成对抗网络的训练-MinMax博弈

对抗训练

- 第一阶段：固定“判别器D”，训练“生成器G”



生成对抗网络

生成对抗网络的训练-MinMax博弈

对抗训练

- 第一阶段：固定“判别器D”，训练“生成器G”
- 第二阶段：固定“生成器G”，训练“判别器D”

固定生成器，提升判别器

生成器
Generator

判别器
Discriminator




生成对抗网络

生成对抗网络的训练-MinMax博弈

对抗训练

- 第一阶段：固定“判别器D”，训练“生成器G”
- 第二阶段：固定“生成器G”，训练“判别器D”
- 循环阶段一和阶段二





生成对抗网络

生成对抗网络的优缺点

3个优势

- 1.能更好建模数据分布（图像更锐利、清晰）
- 2.理论上，GANs 能训练任何一种生成器网络。其他的框架需要生成器网络有一些特定的函数形式，比如输出层是高斯的。
- 3.无需利用马尔科夫链反复采样，无需在学习过程中进行推断，没有复杂的变分下界，避开近似计算棘手的概率的难题。



2个缺陷

- 1.难训练，不稳定。生成器和判别器之间需要很好的同步，但是在实际训练中很容易D收敛，G发散。D/G 的训练需要精心的设计。
- 2.模式缺失（Mode Collapse）问题。GANs的学习过程可能出现模式缺失，生成器开始退化，总是生成同样的样本点，无法继续学习。


生成对抗网络

生成对抗网络的应用

算法	论文	代码
GAN	论文地址	代码地址
DCGAN	论文地址	代码地址
CGAN	论文地址	代码地址
CycleGAN	论文地址	代码地址
CoGAN	论文地址	代码地址
ProGAN	论文地址	代码地址
WGAN	论文地址	代码地址
SAGAN	论文地址	代码地址
BigGAN	论文地址	代码地址



diffusion与GAN的比较-GAN的问题（1/2）



1) 训练不稳定

GAN的核心是一个“生成器”和“判别器”的博弈游戏。两者需要同步优化，但很难保持平衡。就像教两个人同时学习，一个人进步太快会导致另一个人学不到有用的东西，最终导致整个训练过程崩溃，无法得到好的结果。

2) 模式坍塌

指生成器“偷懒”，发现只生成一种或少数几种能骗过判别器的样本就足够了。例如，一个用于生成人脸的GAN可能会塌缩成只生成同一张脸或极其相似的脸，无法覆盖数据集中所有的多样性（如不同肤色、发型、表情等）。

diffusion与GAN的比较-GAN的问题（2/2）

示例：对“panda”图像添加一个经过特殊设计的微小扰动（如Nematode噪声），即可生成一个人类视觉几乎无法察觉差异的“对抗样本”。然而，目标分类模型却会以高达99.3%的置信度将其误判为“gibbon”。该案例深刻揭示了对抗性攻击的威力，同时也映射出GAN训练中的一个核心缺陷，由于其判别器（Discriminator）容易发生评估失准，即便生成器（Generator）已退化至仅输出无意义的噪声（如马赛克图像），判别器仍可能给予其高评价，从而导致模式坍塌（Mode Collapse）。

 x

“panda”

57.7% confidence

 $+ .007 \times$  $\text{sign}(\nabla_x J(\theta, x, y))$

“nematode”

8.2% confidence

 $=$  $x + \epsilon \text{sign}(\nabla_x J(\theta, x, y))$

“gibbon”

99.3 % confidence

diffusion与GAN的比较-Diffusion 的优势（1/1）

➤ 训练更加稳定

GAN在训练时需要仔细选择超参数和正则化项,否则容易出现崩溃的情况。而diffusion模型的训练目标是固定的,更容易训练。

➤ 模式覆盖好

由于其前向过程理论上可以将任何数据都变成噪声,反向过程则学习从噪声恢复到所有可能的数据。因此,它更有可能学会整个数据分布,而不是像GAN那样只学会一部分。生成的样本因此多样性更好,能覆盖训练数据中更多的形态。

➤ 可扩展性更好

由于GAN的训练过程比较复杂,在新领域应用时比较困难。而diffusion模型的训练目标相对简单,可以更容易地应用到新的数据集上。

➤ 样本质量高

diffusion与GAN的比较-Diffusion 的优势 (1/1)





Figure 1: Selected samples from our best ImageNet 512×512 model (FID 3.85)

**GAN模型生
成的图片**


**diffusion模型生成的
图片(2020)**

diffusion与GAN的比较-应用潜力（1/1）

- **图像**：Diffusion模型擅长生成高分辨率图像 和图像编辑（例如图像修复、图像外延和风格迁移）等工作。
- **语音/音频**：Diffusion模型在音频领域同样表现出色，被广泛应用于语音合成（文本到语音TTS）、语音增强、音乐创作和通用音效生成等任务。能够生成高质量、听感自然的语音和音乐，甚至可以对生成音频的音高、能量等属性进行细粒度控制。
- **多模态生成**：扩散模型能很好地与其他模型（如CLIP）结合，根据文本、音频等条件来引导生成过程。最典型的就是“文生图”，能够根据用户输入的文本描述生成高度细致、富有创意甚至达到照片级逼真度的图像。

diffusion基本原理-前向扩散 (1/1)

- 逐步加高斯噪声 → 数据分布接近标准正态 (马尔可夫链建模)



马尔可夫链建模：每一步加噪只依赖于上一步的结果

This diagram shows a single step of the forward diffusion process. It starts with image x_{t-1} , adds noise (indicated by a Gaussian icon and the word "Noise"), resulting in image x_t . The equation below is:


$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_t$$

This diagram shows the cumulative forward diffusion process from x_0 to x_t . It starts with image x_0 , adds noise (indicated by a Gaussian icon and the word "Noise"), resulting in image x_t . The equation below is:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}_t$$
$$\bar{\alpha}_t = \alpha_1 \alpha_2 \dots \alpha_t$$


diffusion基本原理-反向扩散 (1/1)

- 学习逐步去噪，还原原始分布（反向马尔可夫链推导）



diffusion基本原理-训练目标 (1/2)

- MSE 损失 $\approx$ score matching



Diffusion model的训练目标: 最小化预测噪声与真实噪声之间的均方误差(MSE)损失

$$L_{simple} = MSE(\epsilon_t, \epsilon_{\theta}(x_t, t)) = ||\epsilon_t - \epsilon_{\theta}(x_t, t)||^2$$


二、生成模型



西安电子科技大学
XIDIAN UNIVERSITY


diffusion基本原理-训练目标 (2/2)

· 整体架构



应用示例-文本条件生成

- Sora



一个人用生成工具生成一个猫的视频，结果一只真的猫从电脑里跑出来了




Realistic daytime talk show footage filmed with multiple cameras under bright studio lights. A sharply dressed host stands between two blue armchairs on stage. • In one chair sits a calm adult male cat — the alleged father — watching nervously. • In the other chair sits a female cat (the mom) with three tiny 6-week-old kittens huddled together on a blanket. The host holds a card and announces dramatically: “In the case of the three six-week-old kittens... you are NOT the father!” Instantly, the “father” cat leaps from the chair, runs around the set joyfully, jumping on tables and rolling on the floor while the audience laughs and cheers. Cameras cut between the host’s shocked reaction, the mom cat staring in disbelief, and the kittens meowing in confusion. Include handheld camera reactions, audience laughter, and lively studio lighting like a real talk show moment.



三、Transformer


用于Seq2Seq的转换





三、Transformer

用于Seq2Seq的转换
在每个Encoder中提供self-attention




三、Transformer

用于Seq2Seq的转换

在每个Encoder中提供self-attention


Encoder-Decoder Attention：当前翻译和编码的特征向量之间的关系




Self-attention的计算方法

1. 如上文，将输入单词转化成嵌入向量；
2. 根据嵌入向量得到 q , k , v 三个向量；
3. 为每个向量计算一个score: $\text{score} = q \cdot k$;
4. 为了梯度的稳定，Transformer使用了score归一化，即除以 $\sqrt{d_k}$;
5. 对score施以softmax激活函数；
6. softmax点乘Value值 v , 得到加权的每个输入向量的评分 v ;
7. 相加之后得到最终的输出结果 z : $z = \sum v$ 。

Scaled Dot-Product Attention



Multi-Head Attention



Embedding

x_1

x_2

Queries

q_1

q_2

W^Q

Keys

k_1

k_2

W^K

Values


v_1

v_2

W^V

Vision Transformer 图像->patch 将每个patch进行编码

- 我们将一张图像看作“视觉句子”（图像块）的序列；
- 一个视觉句子进一步切分为视觉单词（子图像块）的序列。





四、自监督学习

监督学习

利用大量的标注数据来训练模型，模型的预测和数据的真实标签产生损失后进行反向传播，通过不断的学习，最终可以获得识别新样本的能力。


无监督学习

不依赖任何标签值，通过对数据内在特征的挖掘，找到样本间的关系


自监督学习

主要是利用辅助任务（pretext）从大规模的无监督数据中挖掘自身的监督信息，通过这种构造的监督信息对网络进行训练，从而可以学习到对下游任务有价值的表征。

Supervised



Unsupervised



四、自监督学习


自监督学习

流程

首先从大量的**无标签数据**中通过 pretext 来训练网络，得到预训练的模型，然后对于新的下游任务，和监督学习一样，迁移学习到的参数后微调即可。

自监督学习的能力主要由下游任务的性能来体现。

Self-Supervised Pipeline






四、自监督学习

自监督学习

Momentum Contrast for Unsupervised Visual Representation Learning

$$\mathcal{L}_q = -\log \frac{\exp(q \cdot k_+ / \tau)}{\sum_{i=0}^K \exp(q \cdot k_i / \tau)}$$





自监督学习

Momentum Contrast for Unsupervised Visual Representation Learning

Algorithm 1 Pseudocode of MoCo in a PyTorch-like style.

```
# f_q, f_k: encoder networks for query and key
# queue: dictionary as a queue of K keys (CxK)
# m: momentum
# t: temperature

f_k.params = f_q.params # initialize
for x in loader: # load a minibatch x with N samples
    x_q = aug(x) # a randomly augmented version
    x_k = aug(x) # another randomly augmented version

    q = f_q.forward(x_q) # queries: NxK
    k = f_k.forward(x_k) # keys: NxK
    k = k.detach() # no gradient to keys

    # positive logits: Nx1
    l_pos = bmm(q.view(N,1,C), k.view(N,C,1))

    # negative logits: NxK
    l_neg = mm(q.view(N,C), queue.view(C,K))

    # logits: Nx(1+K)
    logits = cat([l_pos, l_neg], dim=1)

    # contrastive loss, Eqn. (1)
    labels = zeros(N) # positives are the 0-th
    loss = CrossEntropyLoss(logits/t, labels)

    # SGD update: query network
    loss.backward()
    update(f_q.params)

    # momentum update: key network
    f_k.params = m*f_k.params+(1-m)*f_q.params

    # update dictionary
    enqueue(queue, k) # enqueue the current minibatch
    dequeue(queue) # dequeue the earliest minibatch
```

bmm: batch matrix multiplication; mm: matrix multiplication; cat: concatenation.

